

Đánh giá case study cho Continuous Training

BAF với MLP PyTorch và Diabetes Readmission với Logistic Regression

Cập nhật: 17/09/2026

1 Bối cảnh và mục tiêu đánh giá

Định hướng của KLTN là nghiên cứu cách một hệ thống MLOps xác minh model đã suy giảm trong production khi nhân thực tế bị giới hạn. Câu hỏi trung tâm là: với một ngân sách gán nhãn cố định, hệ thống có thể phân biệt suy giảm thật với tín hiệu drift và quyết định Continuous Training an toàn như thế nào?

Report này đánh giá hai workload đã chọn:

1. **Primary case – Bank Account Fraud (BAF):** bài toán deep learning trên dữ liệu tabular động, có mất cân bằng, biến phân loại và thay đổi theo thời gian; phù hợp nhất với research core.
2. **Secondary case – Diabetes Readmission:** bài toán tabular machine learning ở lĩnh vực y tế, dùng để kiểm tra khả năng tổng quát sang domain và model family khác.

BAF nhấn mạnh mất cân bằng, dữ liệu theo thời gian, feature hỗn hợp và thay đổi separability. Diabetes nhấn mạnh nhãn tái nhập viện trễ, replay theo lịch sử dài và khả năng tổng quát sang domain y tế. Hai case dùng chung framework Continuous Training, chỉ thay đổi dataset, model, feature schema, metric chất lượng và tham số scenario.

Ba khái niệm cần được tách rõ trong mọi thực nghiệm:

Drift $\neq$ Degradation $\neq$ Retraining Trigger

Drift chỉ cho biết phân phối đầu vào hoặc đầu ra đã thay đổi. Degradation là suy giảm chất lượng model trên dữ liệu mục tiêu. Retraining trigger là quyết định vận hành sau khi đã xem xét bằng chứng, độ không chắc chắn và ngân sách nhãn.

Pipeline nghiên cứu được mô hình hóa như sau:

Production/Replay -> Predictions + Feedback -> Drift + Quality Estimation -> Evidence Window
-> Degradation Verification -> Budget-aware CT Policy -> KEEP/REQUEST_LABELS/HOLD/RETRAIN
-> Training -> Independent Evaluation Gate -> Promote/Reject/Rollback

Notebook gốc chỉ là baseline tham chiếu. Kết quả cần phân biệt thành ba lớp: kết quả notebook gốc, kết quả model sau khi đóng gói vào MLOps PaaS và kết quả của vòng Continuous Training. Chỉ lớp cuối cùng dùng để kết luận về hiệu quả của đề tài.

2 Khung đánh giá chung và cách tích hợp

Một case study phù hợp với đề tài phải đồng thời có dữ liệu có thể replay theo thời gian, nhãn ẩn để mô phỏng giới hạn quan sát, khả năng tạo prediction có xác suất và metric chất lượng rõ ràng. Quan trọng hơn, case phải cho phép tách riêng chi phí xác minh, chi phí huấn luyện và chi phí đánh giá candidate.

Framework dùng chung cho hai workload gồm:

- **Evidence Window, Drift Detector, CBPE/ATC và Verification Engine:** tạo và kiểm tra bằng chứng về chất lượng.
- **Label Request, Feedback và Label Budget:** quản lý pool nhãn và bảo đảm $B_{verify} + B_{train} + B_{gate} \leq B_{total}$.
- **Decision Policy và Training Orchestrator:** trả về KEEP, REQUEST_LABELS, HOLD hoặc RETRAIN.
- **Evaluation Gate và Replay Harness:** kiểm tra candidate trên holdout độc lập, ghi metrics và bảo đảm thí nghiệm tái lập.

Research layer nên được tách khỏi production platform:

Research layer	replay, scenario, policy, experiment, metrics, results
Production layer	serving, registry, training engine, drift, Kafka, MLflow, deploy

Không cần xây lại model serving, model registry, training engine, drift detector, Kafka/Redpanda, Kubernetes, Terraform hoặc Ansible. Notebook không gọi trực tiếp database hay Kafka; notebook chỉ chịu trách nhiệm preprocessing, training và evaluation. Các service hiện tại chịu trách nhiệm lưu prediction, theo dõi version, ghi lineage, điều phối job và thực hiện callback.

Mỗi run phải ghi commit notebook, dependency, seed, preprocessing, feature list, train/holdout window, snapshot URI và manifest hash. Replay phải deterministic để cùng một scenario có thể chạy lại và so sánh giữa các policy.

3 Case study chính: Bank Account Fraud (BAF)

3.1 Nguồn và bối cảnh ứng dụng

BAF là bộ dữ liệu tabular được giới thiệu trong bài NeurIPS 2022 [Turning the Tables: Biased, Imbalanced, Dynamic Tabular Datasets for ML Evaluation](#). Bộ dữ liệu được sinh từ pipeline bảo toàn riêng tư dựa trên dữ liệu mở tài khoản ngân hàng đã ẩn danh; mỗi bản ghi biểu diễn một hồ sơ mở tài khoản. BAF có nhiều biến thể để kiểm tra mất cân bằng, bias và thay đổi động trong dữ liệu tabular. [Repository và datasheet của tác giả](#).

BAF phù hợp với research core vì kết hợp rare event, limited labels, quality uncertainty và verification cost. Các biến thể cho phép xây temporal replay; Variant V có thể được dùng để tạo stress test thay đổi separability sau giai đoạn đầu. Đây là controlled temporal benchmark, không nên diễn giải như dữ liệu ngân hàng production thô hoặc drift tự nhiên ngoài thực tế.

3.2 MLP và preprocessing

Model chính là MLP PyTorch nhỏ gồm hai hidden layers, ví dụ 128–64 nút, và một output logit. Pipeline cần thực hiện:

- scale numeric features và encode categorical features, có quy tắc xử lý category mới;
- fit preprocessing chỉ trên training partition, xử lý missing/sentinel theo datasheet;
- dùng weighted binary loss, early stopping và chọn decision threshold trên validation;
- lưu preprocessing, weights, schema, label mapping và threshold trong cùng model version.

Month, target và index không được đưa vào predictive input. Month chỉ dùng cho temporal split và phân tích drift. Artifact cuối phải được đóng gói thành MLflow/PyTorch model có wrapper prediction thống nhất với Deep Learning Serving; file weights .pt đơn lẻ chưa đủ để bảo đảm prediction parity.

3.3 Protocol temporal cho Continuous Training

Sau khi kiểm tra file thực tế, protocol khởi đầu có thể dùng các tháng 0–7:

1. tháng 0–3: fit model và preprocessing;
2. tháng 4: validation, chọn hyperparameters và threshold;
3. tháng 5: reference và calibration detector trên partition không giao nhau;
4. tháng 6: predict trước, tính drift, mở nhãn theo độ trễ đã công bố và tạo candidate;
5. tháng 7: future evaluation, không dùng cho tuning hoặc candidate gate.

Để so sánh policy, cần rolling-origin replay qua nhiều tháng và luôn phát prediction trước khi nhãn của tháng đó được mở. Không biến thứ tự dòng CSV thành timestamp giả. Mỗi episode ghi snapshot hash, model version, policy version, label budget và manifest.

3.4 Giá trị đối với đề tài

Với sample nhỏ để verify, có thể thu được rất ít hoặc không có fraud label. Verification Engine vì vậy phải theo dõi đồng thời sample size, positive count và khoảng tin cậy; không kết luận chỉ từ một point estimate như F1 ước lượng. Metrics chính gồm PR-AUC/Average Precision, recall, precision, F1, false negative rate, false positive rate, calibration và số fraud label thu được.

Bảng 1: Đánh giá vai trò của case BAF.

Tiêu chí	Mức phù hợp	Nhận xét
Deep Learning	5/5	MLP PyTorch nhỏ, phù hợp kiểm tra neural artifact và training wrapper.
Class imbalance	5/5	Positive class hiếm làm rõ giới hạn của accuracy và random sampling.
Limited labels	5/5	Có thể đánh giá số positive label thu được trong cùng budget.
Temporal CT	5/5	Có month/variant để xây replay và rolling-origin evaluation.
Quality uncertainty	5/5	Cần sample size, positive count và interval thay vì point estimate.
Khả năng tích hợp	4/5	Phù hợp nhánh PyTorch hiện có nhưng phải kiểm tra preprocessing, dependency và prediction parity.
Rủi ro phương pháp	Một phần	Dữ liệu sinh tổng hợp; protocol temporal là controlled scenario và phải công bố giới hạn.

4 Case study phụ: Diabetes Readmission

4.1 Dataset và workload

Notebook [Fairlearn SciPy 2021 tutorial](#) sử dụng dữ liệu [Diabetes 130-US Hospitals for Years 1999–2008](#) của UCI. Dataset ghi nhận khoảng 101 766 lần nhập viện của bệnh nhân tiểu đường trong mười năm tại 130 bệnh viện hoặc mạng lưới chăm sóc ở Hoa Kỳ, với 47 thuộc tính gốc. Mục tiêu là dự đoán việc tái nhập viện trong vòng 30 ngày.

Phiên bản được dùng trong tutorial Fairlearn đã tiền xử lý thành bài toán nhị phân với 101 766 mẫu và 24 input features. Notebook dùng LogisticRegression, StandardScaler và train_test_split; các metric chính gồm balanced accuracy, ROC-AUC, recall và confusion matrix.

4.2 Điểm mạnh và rủi ro

Case này phù hợp với limited-label verification vì có lịch sử dài để xây replay, chạy được trên CPU và có ý nghĩa nghiệp vụ rõ ràng. Có thể đo degradation tổng thể, sau đó mở rộng sang sai khác giữa các nhóm race, gender hoặc age bằng Fairlearn MetricFrame. Tuy nhiên, dữ liệu không phải production stream; concept drift phải được mô phỏng có kiểm soát và nhân tái nhập viện bị trễ theo thời gian theo dõi.

Fairness nên được giữ ở vai trò **secondary analysis**. Nếu đưa fairness thành research question chính, phạm vi sẽ phình ra và làm loãng đóng góp cốt lõi là xác minh degradation với ngân sách nhãn hạn chế.

4.3 Vai trò trong Continuous Training

Replay của case này nên giữ thứ tự thời gian và tạo các episode theo tháng hoặc theo bệnh viện. Hidden label chỉ được mở trong các pool đã cấp ngân sách. Evidence Window có thể theo dõi đồng thời chất lượng toàn cục và subgroup:

- **Verification:** ước lượng recall, false negative rate hoặc balanced accuracy trên pool kiểm chứng.
- **Training:** dùng một pool riêng để cập nhật model, không dùng lại dữ liệu đã dùng cho gate.
- **Gate:** so sánh candidate với champion trên holdout độc lập; có thể ghi thêm selection rate và chênh lệch true positive rate như phân tích phụ.

Bảng 2: Đánh giá vai trò của case Diabetes Readmission.

Tiêu chí	Mức phù hợp	Nhận xét
Tabular ML	5/5	Logistic Regression dễ chạy CPU, giải thích và calibration.
Limited labels	4/5	Có thể tạo hidden labels và budget pool, nhưng label gốc không đến từ stream thật.
Drift simulation	4/5	Có lịch sử dài; cần thiết kế scenario thay đổi nhóm, bệnh viện và tỷ lệ tái nhập viện.

Tiêu chí	Mức phù hợp	Nhận xét
Degradation study	4/5	Đo được suy giảm tổng thể và subgroup trên các cửa sổ thời gian.
Fairness analysis	5/5	Fairlearn cung cấp metric và mitigation; chỉ dùng làm phân tích phụ.
Tính khả thi 4 tháng	5/5	Nhẹ về compute và phù hợp làm workload tổng quát hóa.
Rủi ro	Cần kiểm soát	Dữ liệu cũ, nhãn là proxy cho nhu cầu chăm sóc và không nên diễn giải như khuyến nghị y tế.

5 So sánh và phân vai trong nghiên cứu

BAF và Diabetes không nhằm tạo hai pipeline độc lập. Chúng dùng chung Evidence Window, Drift Detector, CBPE/ATC, Verification Engine, Label Budget, Decision Policy, Training Orchestrator và Evaluation Gate; chỉ thay đổi dataset, model, feature schema và metric theo domain.

Bảng 3: So sánh hai workload theo mục tiêu thực nghiệm.

Tiêu chí	BAF + MLP	Diabetes + LR	Vai trò
Model family	DL/PyTorch	ML/sklearn	Kiểm tra hai nhánh artifact và serving.
Temporal structure	5/5	4/5	BAF có month/variant; Diabetes có lịch sử dài.
Class imbalance	5/5	3/5	BAF là rare-event stress test chính.
Limited labels	5/5	4/5	BAF đo positive-label scarcity; Diabetes đo nhãn trễ.
Degradation study	5/5	4/5	Cùng policy, khác đặc tính dữ liệu.
Fairness analysis	3/5	5/5	Diabetes dùng subgroup analysis phụ.
Khả năng tích hợp	4/5	5/5	MLP cần wrapper; Logistic Regression phù hợp nhánh sklearn.
Rủi ro validity	3/5	4/5	BAF là dữ liệu sinh; Diabetes có giới hạn đại diện và nhãn proxy.
Tính khả thi 4 tháng	4/5	5/5	Chạy BAF trước, sau đó xác nhận trên Diabetes.

BAF là **primary case** cho RQ1: policy có thể phát hiện degradation và phân bổ nhãn hiệu quả trong một stream fraud động hay không? Diabetes là **secondary case** để kiểm tra generalization sang nhãn trễ, domain y tế và model ML nhẹ hơn. Fairness chỉ được báo cáo như phân tích bổ sung, không trở thành research question mới.

RQ2 không cần thêm một dataset riêng. RQ2 được đánh giá bằng fault-injection campaign chạy trên cùng hai pipeline và một fixture nhỏ có trạng thái xác định. Các lỗi cần chèn gồm reserve quota đồng thời, worker dừng sau commit, callback trễ/lặp/đảo thứ tự, training timeout, candidate crash-loop, champion thay đổi giữa các bước và gate reject. Kết quả cần kiểm tra budget, idempotency, lineage, rollback và việc champion cũ tiếp tục phục vụ.

Notebook CICIDS2017 vẫn giữ vai trò system validation workload cho NIDS: kiểm tra serving, Kafka, Consumer, drift monitoring, logging và workflow end-to-end. Không dùng F1 của CICIDS để so sánh với BAF hoặc Diabetes và không dùng nó làm bằng chứng chính cho RQ1.

6 Protocol thực nghiệm đề xuất

6.1 Experimental scenarios

Mỗi scenario dùng cùng seed, snapshot, label budget, recipe và gate giữa các policy. Replay phải giữ thứ tự thời gian, ẩn ground truth trong lúc policy quyết định và chỉ mở nhãn theo request đã được cấp phép.

Bảng 4: Các scenario tối thiểu.

Mã	Điều kiện	Mục tiêu/kỳ vọng
S0	Stable, không degradation đáng kể	Đo false retraining; kỳ vọng KEEP.
S1	Covariate shift: $P(X)$ thay đổi, $P(Y X)$ gần ổn định	Chứng minh drift không đồng nghĩa degradation.
S2	Harmful drift: phân phối thay đổi và performance giảm	REQUEST_LABELS, VERIFY rồi RETRAIN khi đủ bằng chứng.
S3	Performance/calibration giảm dù input gần ổn định	Chứng minh drift-only không đủ.
S4	Hidden labels với budget giới hạn	Đánh giá policy chọn và phân bổ nhãn.
S5	Drift, degradation, nhãn trễ và budget constraint cùng xuất hiện	Scenario end-to-end quan trọng nhất.

Với Diabetes, scenario nên thay đổi tỷ lệ nhóm, bệnh viện, recall và calibration. Với BAF, scenario nên mô phỏng thay đổi theo tháng, separability, tỷ lệ fraud, category distribution, threshold và calibration.

6.2 Baselines

Bảng 5: Các baseline và policy đối chứng.

Baseline	Cách hoạt động
B0 – Static	Không retrain; đo mức suy giảm tự nhiên.
B1 – Drift-only	Phát hiện drift là trigger retrain ngay, dùng để kiểm tra drift $\neq$ degradation.
B2 – Estimator-only	Dùng CBPE/ATC nhưng không có adaptive verification policy.
B3 – Periodic Labeling	Định kỳ lấy nhãn với budget cố định, không tối ưu theo bằng chứng.
B4 – Proposed Policy	Kết hợp drift, estimated degradation, uncertainty và label budget để ra quyết định.
B5 – Full-label Oracle	Có full ground truth, dùng làm upper bound/reference khi đánh giá.

6.3 Metrics và label pools

Metrics chất lượng gồm precision, recall, F1, PR-AUC/AUPRC, false negative rate, false positive rate và calibration/Brier score. Metrics detection gồm degradation detection rate, missed degradation rate, false trigger rate và verification accuracy. Metrics CT gồm số lần retraining, unnecessary retraining rate, recovery time và time-to-retraining.

Nhóm quan trọng nhất là label efficiency:

- total labels consumed, verification labels, training labels và gate labels;
- số positive/fraud labels thu được;
- label cost và cost per verified degradation;
- tỷ lệ chuẩn hóa $r = B_{\text{labels}}/N_{\text{production}}$.

Ba pool phải độc lập để tránh rò rỉ:

Verification	Training	Gate
ước lượng chất lượng	cập nhật candidate	holdout độc lập

Hệ thống phải enforce $B_{\text{verify}} + B_{\text{train}} + B_{\text{gate}} \leq B_{\text{total}}$. Với BAF, ngoài sample size phải ghi positive count và khoảng tin cậy; sample không có fraud label chưa đủ để kết luận model an toàn.

6.4 Independent Evaluation Gate

Luồng an toàn là:

Training -> Candidate -> Independent Holdout -> Evaluation Gate
-> PROMOTE / REJECT -> Metrics

Gate không dùng dữ liệu đã dùng cho verification, training hoặc policy tuning. Candidate chỉ được promote khi có snapshot, evidence window, training job, build, evaluator result và health record trong cùng lineage. Khi thiếu nhãn, callback trễ, schema sai hoặc gate không đạt, quyết định hợp lệ là HOLD/FAILED có lý do và champion cũ tiếp tục phục vụ.

6.5 Replay harness và kiến trúc experiment

Replay harness cần biến historical dataset thành các batch production có timestamp, prediction và hidden label; sau đó inject scenario, chạy policy, gọi training/gate và xuất metrics. Luồng tối thiểu:

Historical Dataset -> Temporal/Synthetic Batches -> Production Predictions
-> Hidden Labels -> Scenario Injection -> Policy Decisions
-> Training/Gate -> Metrics

Các module nên đặt trong research layer:

- research/replay: stream, scenarios, hidden labels;
- research/policies: static, drift-only, estimator-only, periodic, proposed, oracle;
- research/experiments: run experiment, ablation và configs;
- research/metrics: quality, detection, label cost, retraining và safety.

Production platform giữ các service hiện có. Không đưa logic nghiên cứu vào model serving hoặc registry nếu không cần thiết; thay vào đó, ghi experiment ID, policy version, snapshot hash và kết quả vào lineage để có thể tái lập.

7 Phạm vi khóa luận và khuyến nghị triển khai

Cấu hình nghiên cứu được chốt như sau:

Bảng 6: Cấu hình thực nghiệm đề xuất.

Thành phần	Lựa chọn
Primary workload	Bank Account Fraud (BAF) + MLP PyTorch.
Secondary workload	Diabetes Readmission.
Research problem	Label-efficient degradation verification.
CT contribution	Budget-aware decision policy.
Verification	CBPE/ATC kết hợp selective labels.
Decision	KEEP / REQUEST_LABELS / HOLD / RETRAIN.
Training	Pipeline training hiện có.
Candidate safety	Independent Evaluation Gate.
Main comparison	Static, Drift-only, Estimator-only, Periodic, Proposed, Oracle.
Main constraint	$B_{verify} + B_{train} + B_{gate} \leq B_{total}$.

Trong bốn tháng, phần **must-have** gồm BAF và Diabetes dataset, replay harness, hidden-label mechanism, evidence window, label budget, label request/feedback, CBPE/ATC, verification engine, CT policy, PyTorch/sklearn training integration, independent gate, baselines, controlled scenarios, metrics, ablation và experiment reproducible. CT observability, idempotency, worker failure injection, reconciliation, Argo/Kubernetes end-to-end và Diabetes subgroup analysis là **should-have**.

Không nên mở rộng phạm vi sang LLM, incremental learning, pseudo-labeling, causal inference, advanced HPO, multi-model research, multi-GPU, multi-region HA hoặc autoscaling research. Các hướng đó không cần thiết để trả lời câu hỏi về label-efficient degradation verification.

Thứ tự triển khai nên là: (1) khóa contract prediction và hai baseline; (2) implement replay harness deterministic; (3) thêm hidden labels, evidence window và label pools; (4) tích hợp CBPE/ATC, verification engine và sáu baselines; (5) nối training pipeline và independent gate; (6) chạy S0–S5, ablation và fault injection; (7) so sánh detection rate, missed degradation, unnecessary retraining, label consumption, recovery time và safety promotion.

Đóng góp nên được diễn đạt ở mức có thể kiểm chứng:

A framework for label-efficient degradation verification and budget-aware Continuous Training, evaluated across a rare-event deep-learning workload and a tabular healthcare machine-learning workload.

Không nên claim policy là optimal hoặc áp dụng tốt cho mọi hệ thống ML. Kết luận phải dựa trên trade-off đo được giữa khả năng phát hiện degradation, số degradation bị bỏ sót, chi phí nhân, số lần retraining không cần thiết, thời gian phục hồi và độ an toàn khi promote model.

8 Nguồn tham khảo

1. Jesus, S., Pombal, J., Alves, D., Cruz, A., Saleiro, P., Ribeiro, R., Gama, J., and Bizarro, P., *Turning the Tables: Biased, Imbalanced, Dynamic Tabular Datasets for ML Evaluation*, NeurIPS 2022 Datasets and Benchmarks Track. [Paper page](#); DOI: 10.52202/068431-2432.
2. Feedzai, *Bank Account Fraud Dataset Suite Datasheet*. [Repository và tài liệu dataset](#); [Datasheet PDF](#).
3. Clore, J., Cios, K., DeShazo, J., and Strack, B., *Diabetes 130-US Hospitals for Years 1999–2008*, UCI Machine Learning Repository, DOI: 10.24432/C5230J. [UCI dataset page](#).
4. Fairlearn, *Fairness in AI systems: From social context to practice using Fairlearn*, SciPy 2021 tutorial notebook. [GitHub notebook](#).